



Разработка нейросетевой модели прогнозирования состояния
сезонно-талых грунтов на основе натурных и синтетических
данных

Руководитель: Балута В.И.

Студент: Костанян Э.А.

Цель и задачи

Многолетнемёрзлые грунты — основа инфраструктуры на 60% территории России. Их деградация угрожает устойчивости зданий, дорог и трубопроводов.



Подходы к прогнозу их состояния:

- Эмпирический – накопление натурных данных, статистическая обработка, поиск закономерностей.

Недостатки: данные не покрывают весь диапазон условий, высокая стоимость и трудоёмкость.

- Математическое моделирование – решение уравнений тепло-массопереноса методами вычислительной математики.

Недостатки: требует корректного задания физической модели и больших вычислительных ресурсов.

Модели машинного обучения (как GraphCast для погоды) обучаются на данных и предсказывают за секунды, но и у них **недостатки:** для качественного обучения требуют представительные выборки, а дальнейшее применение требует наличия того же признакового описания.

Задача: разработать модель, обученную на синтетических данных, полученных с помощью комплекса Frost 3D, для мгновенного прогноза глубины протаивания и температур грунта в двух точках железнодорожного полотна.

Формирование массива обучающих данных

Рассматриваются две точки на участке железной дороги Томмот – Нижний Бестях в районе пикета 7179:

- под объектом (по оси насыпи)
- рядом с объектом (естественные условия).




Рисунок 2 – Расчётная область по профилю

1 – ИГЭ-1 мохово-брусничный напочвенный покров; 2 – ИГЭ-2 суглинок; 3 – ИГЭ-3 галька (щебень) с песком

Система описывается входными параметрами:

- Климатические: для каждого месяца заданы средние значения температуры воздуха, высоты снежного покрова и его теплопроводности.
- Грунтовые: для каждого вида грунтов заданы значения влажности, плотности, теплопроводности талого и мёрзлого грунта, теплоёмкости талого и мёрзлого грунта, температуры замерзания.

Всего рассмотрено 5760 расчётных случаев (90 климатических вариантов × 64 грунтовых сценария). Для каждого случая в результате расчётов получаются выходные значения:

- Максимальная глубина протаивания ξ .
- Температуры грунта на глубинах 0–10 м ($T_0, T_1, \dots, T_{10}$).




Классическая регрессия

Чтобы выяснить необходимость нейронных сетей, рассмотрим сначала модели классической регрессии:


- Линейная регрессия.
 - Поиск линейной функции наилучшего приближения: $\sum a_k f_k$
 - Имеет аналитическое решение
 - $(X^T X)^{-1} X^T y$
 - L2- или L1-регуляризация (Ridge, Lasso) ограничивают переобучение.
- Полиномиальная регрессия.
 - Поиск полинома 2-й степени наилучшего приближения: $\sum a_{k,j} f_k f_j$
 - Сводится к линейной регрессии.
 - Позволяет обнаружить нелинейную зависимость.

Классическая регрессия



$$R^2 = 1 - \frac{\sum (y_i - \hat{y}_i)^2}{\sum (y_i - \bar{y})^2}$$


Чем ближе к 1, тем лучше точность модели.




Модель	средний R^2	
	под объектом	рядом с объектом
Линейная регрессия	0.962	0.754
Ridge ($\alpha = 10$)	0.929	0.692
Lasso ($\alpha = 0.1$)	0.823	0.580

Нейронная сеть

- Многослойный перцептрон (MLP) способен аппроксимировать любую непрерывную функцию (теорема об универсальной аппроксимации).
- Рассмотрим три архитектуры: 1, 2 или 3 слоя с функцией активации ReLU. Для каждой из 12 целевых переменных, обучение методом градиентного спуска.
- Сравним разные функции активации на примере 3-слойной модели.



Нейронная сеть




$$R^2 = 1 - \frac{\sum (y_i - \hat{y}_i)^2}{\sum (y_i - \bar{y})^2}$$

Чем ближе к 1, тем лучше точность модели.

Таблица 4.4: Средний R^2 для разных функций активации

Функция активации	Под объектом	Рядом с объектом
ReLU	0.996	0.970
Гиперболический тангенс	0.996	0.968
Логистическая функция	0.995	0.954




- Линейная регрессия не страдает переобучением (регуляризация не улучшила результат).
- Полиномиальная регрессия заметно лучше линейной (зависимость нелинейна), но MLP (256,128) превосходит и её.
- Архитектура (256,128) даёт небольшой, но устойчивый выигрыш по сравнению с одним слоем (64).
- Дальнейшее усложнение (256,128,64) не улучшает результат.
- Смена функции активации не приносит выгоды.

Основной вопрос: почему качество оценки на втором наборе данных (рядом с объектом) систематически хуже?

Сравнительный анализ расчётных участков

На левой панели параметры грунта фиксированы, а климатические меняются. Для каждого набора значений входных параметров строится траектория из 11 выходных значений температур от 0 до 10 метров.



Сравнительный анализ расчётных участков


- *Грунтовые признаки* сами по себе не определяют результирующий температурный профиль: при фиксированном *грунте* смена климата даёт большой разброс результирующих температур. Климатический контекст необходим.
- «Под объектом» при фиксированном климате траектории образуют плотный пучок с малым разбросом выходных значений. Даже без грунтового контекста климат почти полностью определяет результирующий температурный профиль.
Насыпь демпфирует влияние атмосферных факторов, сужая диапазон возможных температурных профилей.
- «Рядом с объектом» траектории широко рассеяны, особенно на глубине. Здесь без грунтового контекста однозначный прогноз невозможен.

Гипотеза:

- Модель, обученная только на климатических признаках, сохранит высокое качество под объектом, но потеряет его рядом с объектом.
- Модель, обученная только на грунтовых признаках, окажется несостоятельной для обеих точек.


Сравнительный анализ расчётных участков

Предсказательная сила климатических признаков (MLP 64)



Модель обучалась только на климатических признаках. Под объектом качество сравнимо с классическими регрессионными моделями. Рядом с объектом качество обвалилось: с около 0.9 до 0.5.

Предсказательная сила грунтовых признаков (MLP 64)



Модель обучалась только на грунтовых признаках. Метрика качества R^2 меньше нуля, то есть точность хуже даже константной оценки средним.

Заключение

- Задача прогноза глубины протаивания и температур грунта решена с помощью нейросетевой модели MLP (256,128), обученной на синтетических данных Frost 3D.
- Полиномиальная регрессия улавливает нелинейность, но MLP даёт устойчивый выигрыш; дальнейшее усложнение архитектуры или смена активации не улучшают результат.
- Ключевое различие двух участков:
 - Под объектом насыпь демпфирует внешние воздействия, и климатические входные параметры объясняют почти всю изменчивость выходных значений ($R^2 = 0.885$); рядом с объектом это не так ($R^2 = 0.608$).
 - Грунтовые параметры играют лишь дополняющую роль и без климатического контекста не определяют результирующий профиль. Чем более однозначна связь между входными климатическими параметрами и выходным температурным профилем, тем лучше модели удаётся его восстановить.
- Итог: качество прогноза ограничивается литологией. Более низкое качество прогнозов рядом с объектом не устраняется усложнением модели.

Спасибо за внимание!